

Proyecto: M.A.R.T.A.

(Mapa de Agua, Recursos, Territorio y Areas verdes)

Equipo: Climate Alchemists

Juan Angel López Delgadillo juan.lopez@cimat.mx
, Luis Osvaldo Cerna Copado luis.cerna@cimat.mx
, Emilio Alejandro Pérez Cerrillo ea.perezcerrillo@ugto.mx
, David de la Rosa Hernandez david.delarosa.hdez@gmail.com

Challenge Community Mapping - Nasa Space Apps Challenge 2024.

octubre, 2024

Descripción.

Plataforma app-web interactiva, multifuncional, preventiva y educativa enfocada al público general, que permite procesar, analizar y predecir consecuencias del potencial impacto climático a diversas comunidades de México. A partir de datos públicos de la CONAGUA, imágenes satelitales proporcionadas por Open-street-maps y las APIS de Google, tenemos el objetivo de informar y concientizar sobre el cambio climático, así como de simular y educar a personas interesadas en el tema.

1. Introducción.

El **cambio climático** es un fenómeno que se manifiesta de maneras cada vez más impactantes; como se ha podido evidenciar en el aumento de temperaturas, siendo 2023 el año con la temperatura más elevada registrado hasta el día de hoy. Esto ha generado una serie de consecuencias graves, entre ellas: la disminución de los recursos necesarios y disponibles para la digna calidad de vida de los integrantes de múltiples comunidades.



Figura 1: El agua y el cambio climático dominan la lista de desastres (ONU)

Esto es una realidad innegable, la cual está transformando nuestro entorno y afectando la vida de millones de personas en todo el mundo a raíz de las problemáticas ambientales que se han difundido desde hace años, como el aumento de las temperaturas, el derretimiento de glaciares, la escasez de

agua y la pérdida de biodiversidad. Comúnmente este discurso señala una comunidad lejana, lo que ha llevado a que sus consecuencias se vean subestimadas por el modo en el que se comunica una información tan crucial y prioritaria como lo es el tema central de esta iniciativa.

Lo anterior, sumado a la cotidiano de vivir cerca de zonas industriales y lo poco acostumbrados a vivir cerca de zonas verdes lleva a la normalización de la coexistencia directa con grandes emisiones de carbono. Como acción de concientización se ha diseñado una forma de comunicar el peligro potencial de las aglomeraciones industriales en zonas específicas de las comunidades, en contraste con los beneficios de las áreas como parques y deportivas; todo por medio de algoritmos de estimación y el uso de las tecnologías de la información para permitir que todo público pueda dimensionar el efecto que tiene nuestra actual forma de utilizar los recursos de la Tierra. En consecuencia, poder tomar decisiones informadas, y por efecto directo, mejores para la comunidad.

Con todo lo ya dicho, se decidió replantear la forma de transmitir esta información a cualquier persona que deseé conocer sobre su comunidad por medio una plataforma app-web interactiva. Esta herramienta facilita el procesamiento, análisis y predicción de los efectos actuales y futuros del cambio climático en diversas comunidades del país. Y aterriza estos conceptos para que las barreras de la edad, conocimiento técnico, etc. sean irrelevantes, democratizando la información y empoderando a

los habitantes con herramientas prácticas y visuales. La visión de esta plataforma es fomentar una respuesta colectiva frente a los desafíos ambientales, promoviendo la resiliencia y un compromiso activo en la protección de nuestro entorno. La educación y la preparación son clave para mitigar los efectos del cambio climático y construir un futuro más sostenible para todos.

2. Ejes del prototipo.

El proyecto se impulsa a partir de los siguientes cuatro pilares:

1. Detección de infraestructura, zonas geográficas y riesgos ambientales por actividad humana.
2. Disponibilidad de zonas de atención médica ante riesgos sanitarios por contaminación.
3. Predicción de tiempos de calor extremo, lluvias y crisis de calidad del aire en regiones geográficas.
4. Simulación de desarrollo sustentable para el rescate ambiental de la región.

3. Preparación de datos:

3.1. Información preliminar del prototipo.

- Se emplearon fuentes de información públicas como **Comisión Nacional del Agua (CONAGUA)**, **Instituto Meteorológico Nacional** para la descarga de bases de datos que sirvieron de entrenamiento y alimentación para los predictores.
- Por otra parte, para los datos geo-satélitales se utilizaron las imágenes de **QGIS** y fuentes de datos públicos de **NASA, ESA (Sentinel-2)**, además de otros proveedores públicos que mencionaremos más adelante.

Se concretó una búsqueda de datos de infraestructuras en la totalidad del **Estado de Guanajuato**, con el objetivo de preparar un conjunto de datos consistente; y así, poder aplicar técnicas efectivas de Aprendizaje Máquina. El *web scraping* se fue realizado a través de la API **Over-Pass-Turbo** que trabaja con los recursos públicos disponibles de la página web de **Open Streets Maps**.

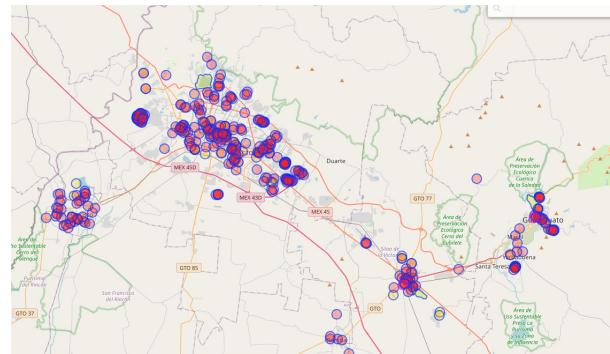


Figura 2: Web Scrapping de las zonas verdes del estado de Guanajuato

Durante el proceso de obtención de datos por medio del *Web Scrapping* masivo se consiguieron los siguientes polígonos de datos:

- Hospitales
- Parques
- Zonas Industriales

Posteriormente, se calcularon las coordenadas centrales de dichas locaciones y por medio de un algoritmo se realizó un conteo del número infraestructuras similares dentro del radio de un kilómetro. Lo anterior permitió asignar un factor de riesgo a las aglomeraciones industriales y un potencial positivo a los grupos de parques e instituciones de salud cercanas.

Con estos datos se realizó lo siguiente:

4. Ejes del Proyecto:

4.1. Detección de infraestructura, zonas geográficas, y riesgos ambientales por actividad humana.

Con el fin de analizar posibles riesgos ambientales derivados de la actividad humana, se generaron modelos de interpolación espacial para estimar la densidad y concentración de infraestructuras en áreas no cubiertas directamente por los datos.

El enfoque principal para este análisis es la interpolación Kriging, una técnica de geoestadística que permite hacer predicciones sobre puntos no observados basándose en la información de puntos observados. A continuación se detalla el proceso y los resultados obtenidos:

4.2. Proceso de Interpolación Espacial con Kriging

Para cada tipo de infraestructura (e.g., hospitales, parques, zonas industriales), se realizó un preprocesamiento y estandarización de los datos geoespaciales y su conteo en un radio de 1 km:

- Preprocesamiento de datos: Los datos fueron filtrados por el tipo de infraestructura utilizando el campo **Tipo**. Esto permite que solo se consideren los puntos relevantes (por ejemplo, zonas industriales) al realizar el análisis de interpolación.
- Estandarización: Se aplicaron transformaciones logarítmicas y estandarización de los valores de conteo (infraestructura en 1 km) para asegurar que los valores sigan una distribución más manejable, especialmente en presencia de ruido o grandes variaciones entre diferentes ubicaciones.
- Modelo Gaussiano: Se utilizó un Proceso Gaussiano (`GaussianProcessRegressor`) con un kernel de tipo `RationalQuadratic`, adecuado para datos que contienen tanto variaciones suaves como bruscas a diferentes escalas, como es el caso de las infraestructuras geográficas.
- Generación de la grilla de puntos: Se creó una grilla regular de coordenadas dentro de los límites espaciales definidos por los datos de latitud y longitud. Esta grilla cubre el área de interés y es el marco sobre el cual se realizan las predicciones de la variable objetivo.
- Predicción de valores: El modelo Kriging entrenado realiza predicciones de la densidad de infraestructuras en cada punto de la grilla, generando un mapa continuo de estimaciones. Estas predicciones son utilizadas para detectar áreas con alta o baja concentración de infraestructuras, lo cual es esencial para evaluar riesgos ambientales asociados.
- Visualización: Los resultados de la interpolación Kriging son representados visualmente mediante un gráfico de contornos que muestra la densidad estimada sobre el mapa de la región. Los sitios observados, es decir, las ubicaciones de infraestructura conocidas, se superponen al gráfico como puntos rojos, permitiendo una comparación directa entre las predicciones y los datos observados.

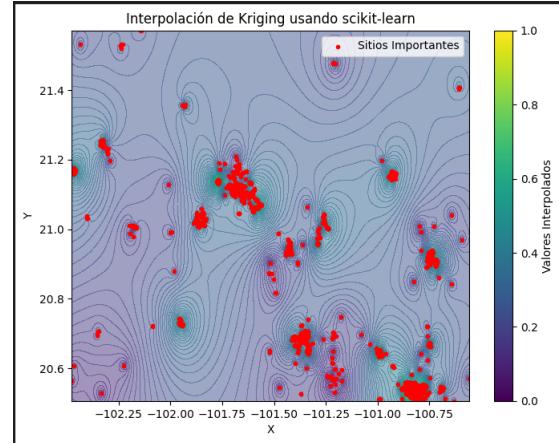


Figura 3: Capa de Kriging

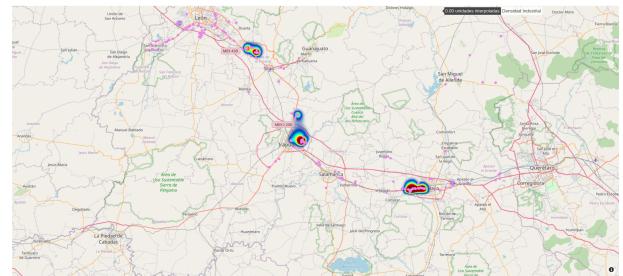


Figura 4: Kriging de Impacto en zonas Industriales en Gto

4.3. Disponibilidad de zonas de atención médica ante riesgos sanitarios por tipo de contaminación

Del mismo modo, se implementó el mismo proceso para poder identificar las zonas de impacto de atención médica ante problemáticas ambientales, ya que existen muchos riesgos de salud. En este caso se puede ver que las zonas de mayor impacto son donde se concentran mayor cantidad de centros médicos, y empieza a notarse en nuestro mapa la falta de servicios de la salud a medida de que uno se aleja. De este modo al comparar las capas de ambos mapas se puede notar la urgencia y la necesidad de construir nuevos centros de atención médica.

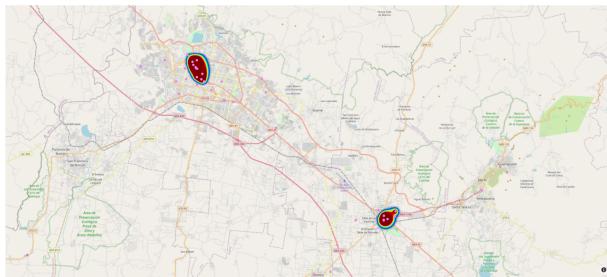


Figura 5: Kriging de impacto y alcance de atención médica ante consecuencias del cambio climático.

El uso de Kriging como herramienta para la interpolación de los datos espaciales es clave para identificar patrones de concentración de infraestructuras. En particular, este enfoque permite extrapolar información de las áreas conocidas a zonas no directamente medidas, proporcionando una visión más completa de la distribución espacial.

4.4. Predicción de tiempos de calor extremo, lluvias y crisis de calidad del aire por regiones geográficas

Para este caso se consideró la recolección de varias estaciones meteorológicas para acceder a sus datos históricos.

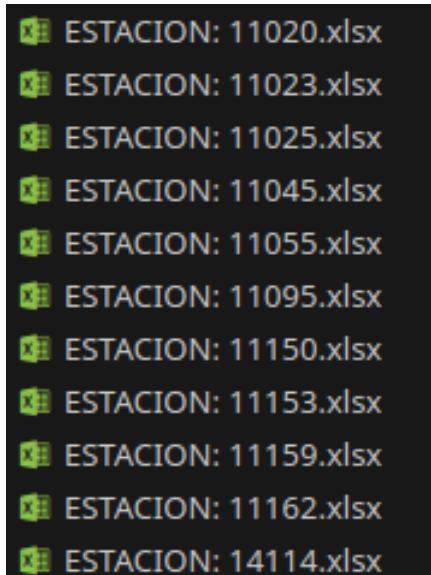


Figura 6: Bases de Datos de los históricos del clima del estado de Gto.

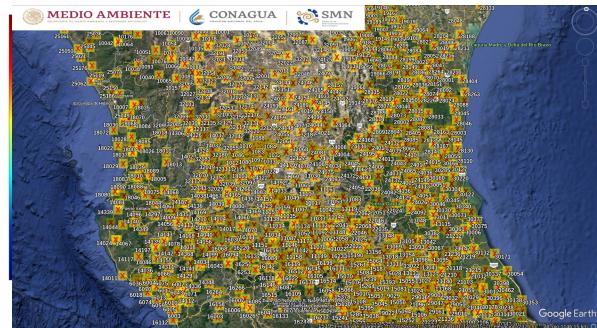


Figura 7: Información de las estaciones meteorológicas de la CONAGUA



Figura 8: Estaciones Meteorológicas en el estado de Gto.

Una vez que se tuvieron acceso a sus históricos se planteó un modelo de **Aprendizaje Máquina** para predecir los siguientes eventos extremos que puede azotar a una comunidad. El modelo que utilizamos fue una **LSTM (Long Short-Term Memory)**, ya que el uso de estas para predecir eventos climáticos extremos es especialmente relevante en el contexto del cambio climático, dado que los patrones climáticos se están volviendo más impredecibles y las temperaturas extremas, así como los episodios de lluvias torrenciales, son cada vez más frecuentes. Las LSTM, debido a su capacidad de mantener y utilizar información a largo plazo, son efectivas para identificar patrones complejos en series temporales, permitiendo una mejor anticipación de dichos eventos y facilitando una planificación más precisa de estrategias de mitigación y adaptación.

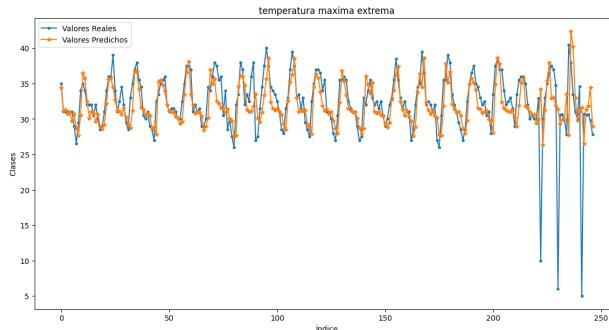


Figura 9: Resultados de la red LSTM para predecir episodios de temperatura extrema en la región de León, Gto.

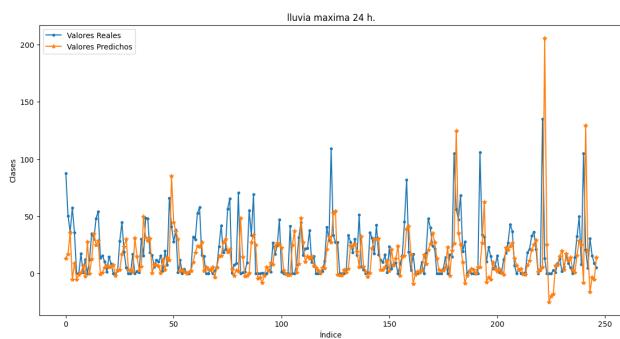


Figura 10: Resultados de la red LSTM para predecir episodios de lluvia máxima en la región de León, Gto.

4.5. Simulación de desarrollo sustentable para el rescate ambiental de la región.

Como parte de nuestra propuesta, buscamos concientizar al público que acceda a nuestro mapa interativo al ofrecer una pequeña simulación que imagina tu comunidad con un mayor aprovechamiento de espacios no ocupados. Para esto,aremos uso de imágenes satelitales y para detectar estos espacios con modelos de aprendizaje maquina.

Antes de comenzar con el entrenamiento de la red neuronal, debemos obtener nuestras imágenes y generar el conjunto de datos que nos interesa. Para obtener las imágenes usamos la aplicación de QGIS, donde por medio de un pequeño scrip de python le pedimos que nos de 150 imágenes aleatorias en la ciudad de León Gto. Para esto, colocamos puntos aleatorios en el mapa centrado en la ciudad y fijamos un nivel de zoom para después exportar la imagen.

Una vez que contamos con nuestras imágenes debemos realizar un proceso de etiquetado, para el cual nos apoyamos de la página Roboflow. Dentro de esta herramienta nos es posible marcar con polígonos las áreas que serán marcadas como "baldeos" para que la red pueda identificar y separar

estas áreas del resto. Manualmente revisamos las 159 imágenes y colocamos un polígono rectangular en las áreas que interpretamos como desprovechadas. Finalmente sepáramos las imágenes en 70 % entrenamiento y 30 % prueba para proceder con el entrenamiento.



Figura 11: Modelo Yolo para la identificación de la tierra

5. Bibliografía.

- Alfaro Posada, Daniel Ignacio (2021). Deteción de objetos a través de imágenes satelitales: caso práctico en la planificación de desarrollo sostenible en zonas rurales de Nikki. Thesis (Master thesis), E.T.S.I. Industriales (UPM)
- Berhan, G., Hill, S., Tadesse, T., & Atnafu, S. (2011). Using satellite images for drought monitoring: a knowledge discovery approach. Journal of Strategic Innovation and Sustainability, 7(1), 135-153.
- Secretaría del Medio Ambiente de la Ciudad de México . (2020). COSECHAR LA LLUVIA MANUAL PARA INSTALAR UN SISTEMA DE CAPTACIÓN PLUVIAL EN TU VIVIENDA. Secretaría Del Medio Ambiente. <https://www.sedema.cdmx.gob.mx/storage/app/media/DGCPCA/ManualCosecharLaLluvia.pdf>
- Contreras Servín, C. (2005). The droughts in Mexico during the XIX Century. Investigaciones Geográficas, 1(56), 118–133. <https://www.scielo.org.mx/pdf/igeo/n56/n56a8.pdf>
- Esparza, M. (2014). La sequía y la escasez de agua en México: Situación actual y perspectivas futuras. Secuencia, 89, 193–219. https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S0186-03482014000200008
- Esquivel, E. (2002). Lluvia y sequía en el norte de México. Un análisis de la precipitación histórica en Chihuahua. In Dialnet (pp.

- 24–42). Gaceta Ecológica. <https://dialnet.unirioja.es/descarga/articulo/2887467.pdf>
- Ultralytics. (s.f.). Ultralytics — Revolutionizing the World of Vision AI. <https://www.ultralytics.com/>
 - Wong, A., Famuori, M., Shafiee, M. J., Li, F., Chwyl, B., Chung, J. (2019, December). YOLO nano: A highly compact you only look once convolutional neural network for object detection. In 2019 Fifth Workshop on Energy Efficient Machine Learning and Cognitive Computing-NeurIPS Edition (EMC2-NIPS) (pp. 22-25). IEEE.